



Universidad Nacional Rosario Castellanos

Licenciatura en Ciencias de Datos para Negocios

Grupo:502

Problema prototípico:

Mercado Justo: Análisis y predicción de precios de productos agropecuarios

Ganadería bovina (enfocado en carne)

Integrantes del equipo:

Megan Cabrera Dimas

Galilea Guadalupe Gomez Guzman

Jonatan Isaac Lopez Mora

Marco Antonio Torres Flores

ÍNDICE

INTRODUCCIÓN	3
PLANTEAMIENTO DEL PROBLEMA	4
JUSTIFICACIÓN	5
OBJETIVO GENERAL	6
MARCO TEÓRICO	8
MARCO REFERENCIAL	9
GANADERÍA BOVINA (ENFOCADO EN EN CARNE).....	10
PROPUESTA DE SOLUCIÓN	21
CONCLUSIÓN	24
ANEXOS.....	25
REFERENCIAS	26

INTRODUCCIÓN

El sector agropecuario mexicano representa uno de los componentes más relevantes para la estabilidad económica, la seguridad alimentaria y el desarrollo social del país. Dentro de este contexto, la ganadería bovina destinada a la producción de carne ocupa una posición estratégica debido a su capacidad para generar empleo, fortalecer las economías rurales y abastecer tanto al mercado nacional como internacional. Sin embargo, los pequeños y medianos productores pecuarios enfrentan un entorno altamente competitivo y vulnerable, caracterizado por la volatilidad de los precios, el incremento constante en los costos de producción y la dependencia de cadenas de intermediación que reducen significativamente sus márgenes de ganancia.

La problemática central radica en la asimetría de información dentro del mercado pecuario. Mientras los grandes comercializadores y distribuidores cuentan con herramientas tecnológicas y datos actualizados para anticipar las fluctuaciones del mercado, las PyMEs ganaderas continúan operando bajo esquemas tradicionales basados en decisiones empíricas. Esta situación provoca incertidumbre financiera, baja capacidad de negociación y dificultades para planificar la producción y comercialización de manera eficiente.

Ante este panorama, el proyecto “Mercado Justo: Análisis y Predicción de Precios de Productos Agropecuarios” propone la integración de herramientas de Ciencia de Datos para Negocios, Big Data, Machine Learning, Minería de Datos e Investigación de Operaciones con el propósito de transformar los registros históricos de comercialización en conocimiento estratégico y predictivo. Mediante el análisis de más de catorce mil registros comerciales relacionados con la carne bovina en la región centro de México, se busca desarrollar modelos matemáticos y algoritmos inteligentes capaces de identificar patrones de comportamiento, pronosticar precios futuros y optimizar las decisiones logísticas y comerciales de los productores.

El proyecto incorpora metodologías avanzadas como árboles de decisión, modelos autorregresivos ARIMA, Facebook Prophet y programación lineal, permitiendo construir un sistema predictivo y prescriptivo que reduzca la incertidumbre económica y favorezca un esquema de comercio más equitativo. Asimismo, se integra una perspectiva de sostenibilidad y justicia social, promoviendo la participación de las mujeres rurales y fortaleciendo el acceso de las comunidades agropecuarias a tecnologías de análisis de datos que impulsen su competitividad y autonomía económica.

En consecuencia, esta investigación no solo representa una aplicación tecnológica innovadora dentro del sector pecuario, sino también una propuesta estratégica orientada a democratizar la información del mercado, mejorar la rentabilidad de las unidades productivas y consolidar un modelo de comercialización más eficiente, inclusivo y sustentable para la ganadería bovina mexicana.

PLANTEAMIENTO DEL PROBLEMA

La ganadería bovina enfocada en la producción de carne constituye una de las principales actividades económicas del sector agropecuario en México; sin embargo, las pequeñas y medianas unidades de producción enfrentan severas dificultades para competir dentro de un mercado caracterizado por la volatilidad de precios, el incremento de costos operativos y la concentración del poder comercial en intermediarios y grandes distribuidores.

Uno de los principales problemas estructurales es la asimetría de información existente entre productores e intermediarios. Mientras los actores comerciales con mayor capacidad financiera poseen acceso a información actualizada, sistemas de análisis de mercado y herramientas tecnológicas avanzadas, los pequeños ganaderos continúan tomando decisiones de venta y distribución de manera empírica, sin fundamentos estadísticos o predictivos que les permitan anticipar el comportamiento de los precios.

Esta situación provoca que los productores venden su ganado bajo condiciones desfavorables para cubrir costos inmediatos relacionados con alimentación, transporte, medicamentos, infraestructura y mantenimiento del ganado. Como consecuencia, gran parte del valor agregado de la cadena de suministro es capturado por intermediarios, reduciendo significativamente la rentabilidad de las PyMEs pecuarias y limitando su crecimiento económico.

Adicionalmente, factores externos como la inflación, las condiciones climáticas, la escasez de agua, la variación en los precios de los granos y la demanda del mercado nacional e internacional generan fluctuaciones constantes en el precio de la carne bovina. La ausencia de modelos predictivos y sistemas de optimización logística dificulta la planeación financiera y operativa de los productores, incrementando el riesgo económico y la vulnerabilidad del sector.

Por lo tanto, surge la necesidad de desarrollar un sistema analítico basado en Ciencia de Datos para Negocios que permita procesar grandes volúmenes de información histórica, identificar patrones de comportamiento del mercado y generar predicciones confiables sobre los precios futuros de la carne bovina. Asimismo, resulta indispensable implementar modelos de optimización matemática que ayuden a determinar estrategias eficientes de distribución y comercialización, fortaleciendo la competitividad y sostenibilidad de las pequeñas y medianas empresas ganaderas de la región centro de México.

JUSTIFICACIÓN

La pertinencia y fundamentación de esta investigación se justifica de manera multidimensional en la intersección de la soberanía agroalimentaria, la equidad socioeconómica y la aplicación avanzada de la Ciencia de Datos en entornos corporativos y de agronegocios en la región centro de México. Desde una perspectiva económica y de organización industrial, la cadena de valor de la carne bovina adolece de fallas de mercado estructurales provocadas por una distribución asimétrica del poder de negociación y del acceso a la información simétrica. Los pequeños y medianos productores pecuarios (PyMEs), al operar bajo esquemas tradicionales desprovistos de certidumbre matemática sobre los movimientos de los precios, absorben la totalidad de los riesgos climáticos, las fluctuaciones biológicas del ganado y los costos fijos de mantenimiento en corral. En contraste, los intermediarios financieros, acopiadores y distribuidores mayoristas capturan el mayor porcentaje del valor agregado de la cadena mediante la especulación basada en la urgencia de liquidez del ganadero primario.

Justificar este estudio implica dotar a las unidades productivas de una plataforma analítica de carácter predictivo y prescriptivo que rompa esta dinámica de subordinación comercial, traduciendo catorce mil registros históricos de transacciones en reglas lógicas condicionales y vectores temporales que democratizan el conocimiento del mercado. Desde el punto de vista de la mercadotecnia estratégica y la optimización de operaciones, la investigación se fundamenta en la necesidad imperativa de transicionar de una comercialización empírica y genérica donde la carne se vende como un *commodity* vulnerable hacia un modelo de toma de decisiones de precisión, donde las variables operativas de la mezcla de mercadotecnia (Producto, Precio, Plaza y Promoción) se configuren de forma óptima para maximizar la utilidad neta y asegurar el retorno de inversión de la unidad pecuaria.

Por lo tanto, la justificación metodológica y social del proyecto se consolida al demostrar que el uso de algoritmos de aprendizaje supervisado, modelos autorregresivos y programación lineal no solo incrementa la eficiencia de las PyMEs ganaderas, sino que valida la viabilidad práctica y la replicabilidad del concepto de Mercado Justo mediante el uso riguroso de la ciencia de datos aplicable a los negocios.

OBJETIVO GENERAL

Desarrollar un sistema metodológico predictivo y prescriptivo fundamentado en minería de datos, machine learning, modelos econométricos e investigación de operaciones sobre una base de catorce mil registros comerciales, para modelar las fluctuaciones del precio por kilogramo de carne bovina en la región centro del país y determinar el volumen óptimo de distribución logística que maximice el beneficio financiero de los pequeños y medianos productores frente a las asimetrías del mercado tradicional.

Objetivos Específicos

- Recopilar, depurar y transformar los registros históricos de comercialización de carne bovina mediante técnicas de limpieza de datos, codificación categórica e ingeniería de variables para garantizar la calidad y consistencia de la información.
- Analizar el comportamiento de las variables económicas, productivas y comerciales que influyen en el precio de la carne bovina, identificando patrones y tendencias relevantes mediante técnicas de análisis exploratorio de datos.
- Implementar modelos de aprendizaje automático basados en árboles de decisión y Random Forest para predecir el precio por kilogramo de carne bovina a partir de variables como región, demanda, oferta, tipo de alimentación y canal de comercialización.
- Desarrollar modelos econométricos autorregresivos ARIMA y Prophet para proyectar el comportamiento futuro de los precios y analizar la tendencia temporal del mercado pecuario.
- Formular un modelo de optimización lineal que determine el volumen óptimo de distribución y comercialización capaz de maximizar la utilidad neta de las PyMEs ganaderas.
- Diseñar herramientas visuales e interactivas que permitan interpretar los resultados del análisis predictivo y apoyar la toma de decisiones estratégicas dentro de la cadena de suministro agropecuaria.
- Promover un modelo de comercio justo mediante el uso de tecnologías analíticas que reduzcan la dependencia de intermediarios y fortalezcan la participación económica de los productores rurales.

MARCO TEÓRICO

1. Ganadería bovina en México

La ganadería bovina representa una de las actividades más importantes del sector agropecuario mexicano debido a su contribución al Producto Interno Bruto agropecuario, la generación de empleos y el abastecimiento de proteína animal para la población. México destaca además como exportador de carne bovina hacia mercados internacionales, principalmente Estados Unidos.

Los sistemas de producción bovina varían según las condiciones geográficas y climáticas del país. En la región norte predominan sistemas extensivos, mientras que la región centro combina modelos semi-intensivos basados en pastoreo y suplementación alimentaria. Estos sistemas impactan directamente en los costos de producción, la calidad de la carne y el comportamiento de los precios.

2. Dinámica de precios en el mercado pecuario

El precio de la carne bovina depende de múltiples factores económicos y ambientales, entre ellos:

- Oferta y demanda del mercado.
- Costos de alimentación y transporte.
- Inflación y tipo de cambio.
- Condiciones climáticas.
- Capacidad de exportación.
- Participación de intermediarios.

La volatilidad de estos factores provoca incertidumbre financiera en los pequeños productores, quienes generalmente carecen de herramientas para anticipar cambios en el mercado.

3. Ciencia de Datos aplicada a los agronegocios

La Ciencia de Datos permite transformar grandes volúmenes de información en conocimiento útil para la toma de decisiones estratégicas. Dentro del sector agropecuario, esta disciplina facilita el análisis de tendencias de producción, comercialización y comportamiento del mercado.

Las principales etapas de la Ciencia de Datos incluyen:

- Recolección de datos.
- Limpieza y transformación.
- Análisis exploratorio.
- Modelado predictivo.
- Visualización de resultados.
- Optimización de decisiones.

4. Minería de Datos y Machine Learning

La minería de datos se enfoca en descubrir patrones ocultos dentro de grandes bases de información. En este proyecto, se utilizan algoritmos supervisados como Random Forest y árboles de decisión para analizar el comportamiento del precio de la carne bovina.

El Machine Learning permite construir modelos capaces de aprender automáticamente a partir de datos históricos, mejorando la precisión de las predicciones y facilitando la identificación de variables relevantes para el negocio pecuario.

5. Modelos econométricos de series temporales

Los modelos ARIMA y Prophet permiten analizar el comportamiento cronológico de los precios mediante el estudio de tendencias, estacionalidad y variaciones temporales.

El modelo ARIMA se basa en la dependencia de valores rezagados y permite proyectar precios futuros utilizando patrones históricos. Por otra parte, Prophet incorpora componentes estacionales y tendencias complejas que facilitan el análisis predictivo en horizontes de mediano plazo.

6. Investigación de Operaciones y optimización logística

La Investigación de Operaciones aplica modelos matemáticos para optimizar recursos y procesos empresariales. En el contexto pecuario, la programación lineal permite determinar el volumen óptimo de producción y distribución que maximiza las ganancias y minimiza costos logísticos.

Asimismo, herramientas de optimización de redes y rutas permiten mejorar la eficiencia del transporte y fortalecer la cadena de suministro agropecuaria.

7. Big Data en el sector agropecuario

El crecimiento de los registros digitales en el sector agropecuario ha impulsado la adopción de tecnologías Big Data para procesar grandes volúmenes de información en tiempo real. Plataformas como PySpark facilitan el análisis distribuido de datos y permiten trabajar con miles de registros comerciales de manera eficiente.

Estas tecnologías fortalecen la capacidad analítica de las organizaciones y mejoran la toma de decisiones estratégicas en agronegocios.

MARCO REFERENCIAL

El proyecto “Mercado Justo” se desarrolla tomando como referencia el contexto agropecuario de la región centro de México, donde la producción bovina constituye una de las principales actividades económicas rurales. Estados como Jalisco, Guanajuato, Michoacán, Querétaro y Estado de México concentran una importante participación en la comercialización y distribución de carne bovina.

La investigación se fundamenta en el análisis de una base de datos conformada por más de 14,000 registros históricos relacionados con variables comerciales y productivas, entre ellas:

- Precio por kilogramo.
- Volumen de ventas.
- Tipo de alimentación.
- Estado de origen.
- Mercado de comercialización.
- Inflación.
- Temperatura.
- Oferta y demanda.

El procesamiento de la información se realiza mediante herramientas de análisis de datos como Python, Pandas, PySpark, Scikit-learn, Statsmodels y Prophet, integrando técnicas avanzadas de modelado predictivo y optimización matemática.

Asimismo, el proyecto toma como referencia estudios previos relacionados con:

- Predicción de precios agropecuarios.
- Optimización logística en cadenas de suministro.
- Aplicaciones de Big Data en agronegocios.
- Modelos econométricos de series temporales.
- Sistemas inteligentes de apoyo a decisiones empresariales.

El entorno de aplicación se orienta principalmente a las pequeñas y medianas empresas ganaderas que requieren herramientas tecnológicas accesibles para mejorar su competitividad, reducir riesgos financieros y fortalecer su capacidad de negociación dentro del mercado pecuario mexicano.

GANADERÍA BOVINA (ENFOCADO EN EN CARNE)

El desarrollo de la actividad pecuaria en México, y de manera específica la producción de ganadería bovina orientada al abasto de carne en la región centro del país, constituye un eje socioeconómico estratégico que enfrenta un escenario de alta vulnerabilidad debido a la asimetría de información y a la volatilidad de los precios de mercado. El incidente crítico estructural que da origen a este estudio radica en la inestabilidad de los ingresos de las pequeñas y medianas unidades de producción (PyMEs), cuyas fluctuaciones dependen de variables exógenas como los ciclos climáticos, los costos de los insumos y la presión ejercida por redes de intermediación especulativa. Cuando los productores carecen de herramientas analíticas, se transforman en tomadores de precios y se ven obligados a liquidar su inventario vivo bajo condiciones desfavorables para cubrir sus costos operativos fijos. La Ciencia de Datos para Negocios interviene en este contexto como una disciplina prescriptiva, proveyendo los métodos científicos necesarios para transformar catorce mil registros históricos de transacciones en conocimiento accionable y optimizar la cadena de suministro bajo principios de justicia distributiva. Para reestructurar esta cadena de valor, la zootecnia y la economía se fusionan con el marketing estratégico a través de la mezcla de mercadotecnia, donde el producto se diferencia mediante atributos de calidad, trazabilidad y corte, sustituyendo el concepto de bien genérico. El precio se gestiona dinámicamente mediante proyecciones econométricas, la plaza se expande mediante canales digitales que conectan directamente al productor con el consumidor institucional, y la promoción comunica los valores de comercio justo para capturar nichos de mercado con mayor disposición al pago.

La fundamentación metodológica para el tratamiento de la base de datos se alinea con los estándares de la minería de datos, implementando la carga, limpieza, validación de tipos e ingeniería de variables mediante un entorno de computación distribuida apto para grandes volúmenes de información corporativa. En primer lugar, se establece un ecosistema informático mediante la inicialización de una sesión de cómputo en la nube a través de la clase `SparkSession` de PySpark, la cual es configurada bajo la aplicación denominada `"BigDataCarneBovina"` para garantizar la gestión distribuida de los catorce mil registros extraídos del archivo maestro en formato Excel. Al integrar la biblioteca Pandas para la lectura inicial y mapear su estructura nativa hacia un `DataFrame` distribuido de PySpark, el sistema ejecuta la validación automatizada de las variables y el esquema de los datos (`printSchema`), lo que permite diagnosticar las propiedades cualitativas y cuantitativas iniciales del fenómeno.

La matriz de información inicial revela una composición heterogénea estructurada en once columnas base: `fecha` (registrada originalmente como cadena de texto), `estado`, `producto`, `mercado`, `tipo_alimentacion`, `demanda` y `oferta` (como variables categóricas o cadenas), junto con los vectores numéricos correspondientes a `precio_kg` y `ventas` (almacenados inicialmente como enteros largos), `inflacion` (codificada en coma flotante de doble precisión) y `temperatura`. Con la finalidad de adecuar esta estructura hacia los requerimientos algorítmicos y evitar inconsistencias en el espacio de almacenamiento físico, se ejecuta un proceso explícito de conversión de tipos de datos (`cast`). Mediante la aplicación de las clases `DateType` e `IntegerType`, la columna cronológica se transforma formalmente en un tipo fecha, mientras que las variables operativas `precio_kg`, `ventas` y `temperatura` se restringen a

enteros estándar para homogeneizar los vectores de características. Paralelamente, se implementa una rutina de auditoria de datos perdidos que evalúa fila por fila la presencia de valores nulos a través de filtros condicionales (`isNull`); este diagnóstico computacional confirma un vector con cero nulos en todas las dimensiones de la base del problema prototípico, garantizando la integridad referencial para el modelado matemático subsiguiente sin requerir algoritmos complejos de imputación por vecindad o media móvil en esta fase de limpieza.

Una vez estabilizada la base informativa, el componente operativo activa una fase de ingeniería de características (*feature engineering*) orientada a capturar patrones estacionales y cíclicos incrustados en la línea temporal. A través de funciones vectoriales del módulo `pyspark.sql.functions` (`year`, `month`, `dayofmonth`, `dayofweek`), el registro de tiempo se descompone de forma recursiva para instanciar cuatro dimensiones numéricas adicionales: el año de la transacción (`anio`), el mes calendario (`mes`), el día del mes (`dia_mes`) y el día de la semana (`dia_semana`), donde los valores son mapeados en un rango entero que categoriza matemáticamente desde el día domingo hasta el sábado. Esta descomposición multidimensional dota al modelo de la capacidad de aislar variaciones de precios asociadas a picos de consumo mensuales o dinámicas operativas semanales en los centros de acopio.

Para transitar del plano descriptivo y predictivo, las variables categóricas nominales sin orden intrínseco, como el estado de origen (`estado`), el mercado de destino (`mercado`) y el tipo de corte (`producto`), junto con los factores determinantes de `tipo_alimentacion`, `demandas` y `ofertas`, son procesadas formalmente mediante un proceso automatizado de indexación numérica a través de la clase `StringIndexer`. Este estimador codifica cada categoría textual en etiquetas numéricas de tipo doble en función de la frecuencia de aparición de los datos, mitigando la introducción de relaciones espurias de magnitud en los algoritmos predictivos. Posteriormente, el vector total de características se unifica mediante la clase `VectorAssembler`, la cual concatena los seis vectores categóricos indexados y las siete variables numéricas nativas en una sola columna condensada denominada `features`, preparando el espacio multidimensional que será consumido por el algoritmo de aprendizaje estadístico. El análisis exploratorio de datos (EDA) derivado de esta estructuración demuestra de manera consistente una tendencia alcista a largo plazo vinculada a la inflación de insumos, una marcada dispersión de precios según la especialización del corte, y un impacto directo del tipo de alimentación en el precio final en canal, donde los sistemas intensivos estabulados perciben un premio económico debido al rendimiento y homogeneidad del marmoleo de la carne.

Para descifrar las interacciones que determinan la fijación del precio por kilogramo de carne, el procedimiento analítico implementa un robusto modelo predictivo multivariable basado en un Ensamble de Árboles de Decisión para Regresión mediante la clase `RandomForestRegressor`, configurado con un bosque estocástico de cien árboles independientes (`numTrees=100`) para maximizar la estabilidad de las predicciones frente a perturbaciones en los datos. El conjunto de datos unificado se segmenta mediante una partición aleatoria que destina el ochenta por ciento de los registros al entrenamiento del algoritmo (`training_data`) y aísla el veinte por ciento restante bajo un principio de validación ciega (`test_data`) para mitigar el sobreajuste, utilizando una semilla de aleatoriedad fija para asegurar la replicabilidad exacta

del experimento. El algoritmo opera ejecutando divisiones recursivas del espacio multidimensional de las variables explicativas, seleccionando en cada nodo el parámetro que maximiza la reducción de la varianza del precio. La función objetivo para determinar la mejor partición en un nodo T se fundamenta en la minimización de la suma de los errores al cuadrado, expresada matemáticamente como:

$$SSE = \sum_{i \in T_L} (y_i - \hat{y}_{T_L})^2 + \sum_{i \in T_R} (y_i - \hat{y}_{T_R})^2$$

Donde y_i representa el precio real por kilogramo del registro i , mientras que $\hat{y}_{T_L}$ y $\hat{y}_{T_R}$ corresponden a los precios promedio estimados de los subconjuntos izquierdo y derecho resultantes de la división, respectivamente. Al controlar la profundidad del árbol para preservar su interpretabilidad y promediar los resultados del ensamble, el modelo genera un conjunto fluido de reglas condicionales entonces que determinan el valor esperado de la carne en función de las variables operativas. ras procesar los datos de prueba y contrastar los valores reales contra las predicciones del modelo (por ejemplo, proyectando un precio estimado de \$285.14 para un valor real de \$277.00, o de \$335.05 frente a un costo real de \$340.00), el sistema evalúa su precisión global empleando la clase [RegressionEvaluator](#). El rendimiento del modelo registra un Error Absoluto Medio (MAE) de catorce pesos con veinticinco centavos (MAE = 14.25) y una Raíz del Error Cuadrático Medio de diecisiete pesos con setenta y un centavos (RMSE = 17.71). La formulación matemática del error absoluto responde a la ecuación:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Esta métrica mide la magnitud promedio de los errores de predicción en las mismas unidades que la variable objetivo (pesos por kilogramo), proporcionando una interpretación directa de la desviación del modelo respecto a los precios reales del mercado.

Para robustecer la confianza del tomador de decisiones, la unidad de negocio complementa la analítica computacional mediante un análisis visual estratégico que grafica el rendimiento del modelo en una muestra cronológica de doscientos registros rezagados utilizando las bibliotecas Matplotlib y Seaborn. Esta visualización proyecta de forma simultánea una curva continua en color azul rey que mapea los precios reales por kilogramo contra una línea discontinua en color naranja oscuro que traza las predicciones estimadas por el bosque estocástico. La superposición geométrica de ambas curvas permite comprobar visualmente la capacidad del algoritmo para capturar los puntos de inflexión temporal y la

dispersión de las cotizaciones, consolidando una herramienta de diagnóstico intuitiva para las PyMEs pecuarias.

De forma simultánea, el comportamiento inercial y temporal de las cotizaciones se analiza de manera complementaria mediante modelos autorregresivos integrados de media móvil (ARIMA). El procedimiento econométrico requiere el ordenamiento cronológico estricto de las transacciones y la regularización de la serie para forzar una frecuencia diaria. La ausencia de datos en días inhóspitos se resuelve mediante un método de propagación hacia adelante, imputando en los campos vacíos el último precio conocido para garantizar la continuidad geométrica de la serie. Al calibrar el modelo temporal con un orden autorregresivo puro de Pipas periodos, denotado como un proceso AR(5) o ARIMA(5,1,0) tras aplicar una diferenciación para inducir estacionariedad, se formaliza la dependencia estructural del precio actual respecto a sus valores rezagados. La ecuación general que rige este comportamiento temporal se define matemáticamente como:

$$Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \phi_3 Y_{t-3} + \phi_4 Y_{t-4} + \phi_5 Y_{t-5} + \epsilon_t$$

Donde $\hat{y}_t$ es el valor del precio diferenciado en el tiempo t , c representa una constante determinada por la deriva de la serie, $\phi_1, \dots, \phi_5$ corresponden a los coeficientes autorregresivos que ponderan la influencia del pasado, y ϵ_t representa el término de ruido blanco o error estocástico contemporáneo, el cual se asume idéntica e independientemente distribuido con media cero y varianza constante. Al proyectar la serie hacia un horizonte de mediano plazo fijado en treinta días futuros, la curva de predicción tiende a estabilizarse de forma asintótica en una línea horizontal alineada con la media histórica reciente, un comportamiento estadísticamente normal en procesos autorregresivos puros estables cuando se extienden más allá de su memoria de corto plazo, proveyendo al productor de una línea base de alta confiabilidad para la planificación de sus flujos de caja y la gestión de su liquidez inmediata.

Para robustecer y complementar este análisis temporal, la arquitectura analítica acopla el modelo predictivo Facebook Prophet. Mientras que ARIMA fundamenta su proyección en la dependencia lineal de los rezagos inmediatos, Prophet aborda las cotizaciones bajo un enfoque de modelo estructural generalizado. Este enfoque descompone la serie temporal de forma aditiva en tres componentes principales de comportamiento estocástico más un término de error:

$$y(t) = g(t) + s(t) + h(t) + \epsilon_t$$

Donde $g(t)$ representa la tendencia de crecimiento a largo plazo (asociada en este ecosistema a la inflación de insumos), $s(t)$ modela las variaciones estacionales periódicas, $h(t)$ representa el impacto de

días festivos o eventos comerciales imprevistos, y ϵ_t Es el factor de error aleatorio. Mediante este tratamiento, el sistema inicializa un DataFrame específico donde la línea cronológica y el vector de precios se mapean estrictamente hacia las variables nativas del algoritmo (**ds** y **y**, respectivamente). Al configurar y ajustar el modelo activando de forma explícita los parámetros de estacionalidad anual (**yearly_seasonality=True**) y semanal (**weekly_seasonality=True**), Prophet aísla de manera recursiva los impactos cíclicos recurrentes del mercado pecuario, tales como los picos de demanda mensuales o las fluctuaciones operativas semanales extraídas en la fase de ingeniería de características. Al extender la línea temporal mediante la generación de un horizonte futuro y ejecutar la inferencia estocástica para los próximos treinta días, el algoritmo proyecta curvas continuas de tendencia que capturan la ciclicidad intrínseca del negocio, aportando bandas de incertidumbre y un marco predictivo visual que optimiza de forma paralela la planeación financiera estratégica.

El conocimiento predictivo y paramétrico extraído de la base de datos históricos se transforma en una estrategia prescriptiva mediante la formulación de un modelo de optimización lineal basado en los principios de la Investigación de Operaciones. El objetivo central consiste en determinar la cantidad exacta de masa en kilogramos que la organización pecuaria debe distribuir diariamente para maximizar su beneficio económico neto, superando los esquemas empíricos de venta desordenada. A partir del procesamiento estadístico descriptivo de los catorce mil registros de la base de datos real del problema prototípico, se determinaron los parámetros financieros de control. El precio promedio real de comercialización de la carne bovina en la región centro, denotado como la constante P , se fijó en doscientos cuarenta y nueve pesos con cuarenta y nueve centavos por kilogramo ($P = 249.49$). El costo de producción unitario estándar para las PyMEs pecuarias de la región, denotado como la constante C , se estableció en ciento sesenta pesos con cero centavos por kilogramo ($C = 150.00$), consolidando los costos variables de alimentación, fletes logísticos y costos fijos prorrateados.

La función objetivo del modelo matemático busca maximizar la ganancia neta total (G), definida algebraicamente como la diferencia entre la función de ingresos totales (I) y la función de costos totales (K), ambas dependientes de la variable de decisión v , que representa el volumen de kilogramos a vender por ciclo operativo. El desarrollo estructural del modelo se rige por el siguiente sistema de ecuaciones y restricciones lineales:

$$\text{Maximizar } G(v) = I(v) - K(v)$$

Donde las funciones componentes se definen como:

$$I(v) = v \cdot P$$

$$K(v) = v \cdot C$$

Al sustituir los parámetros reales del problema prototípico, la función objetivo se reduce a la expresión:

$$G(v) = v \cdot \$249.49 - v \cdot \$150.00 = v \cdot (\$249.49 - \$150.00) = v \cdot \$99.49$$

El sistema registra este valor y lo establece como la primera base de decisión. Posteriormente, el procedimiento de optimización avanza a través de los escenarios incrementales desde $v = 51$ hasta $v = 148$. Para cada incremento unitario en la variable de decisión, el algoritmo computa de manera estricta las nuevas funciones lineales. Debido a la constancia del margen unitario de más noventa y nueve pesos con cuarenta y nueve centavos, el modelo comprueba que cada incremento de un kilogramo inyecta exactamente ese valor neto adicional a la utilidad total del periodo. Al evaluar la condición de optimización:

$$G(v + 1) > G(v)$$

El sistema valida en cada vuelta del ciclo que la ganancia neta del escenario actual supera de forma consistente a la del escenario anterior. Como consecuencia de esta linealidad ascendente, el algoritmo desplaza de manera ininterrumpida el vector de decisión hacia el extremo derecho del espacio factible, descartando los puntos intermedios como soluciones subóptimas que representan un costo de oportunidad por subutilización de la capacidad instalada de transporte logístico.

El procedimiento iterativo alcanza su resolución definitiva al evaluar el escenario máximo permitido antes de saturar la capacidad de transporte, correspondiente a un volumen de venta de ciento cuarenta y nueve unidades ($v = 149$), que representa el límite superior estricto determinado por el rango del ciclo operativo del programa. En esta iteración culminante, el desarrollo matemático registra el cálculo final de ingresos y costos acumulados:

$$I(149) = 149 \cdot \$249.49 = \$37,174.01$$

$$K(149) = 149 \cdot \$150.00 = \$22,350.00$$

Al ejecutar la operación sustractiva fundamental para aislar el rendimiento neto del agronegocio, el modelo matemático concluye con la siguiente resolución exacta:

$$G(149) = \$37,174.01 - \$22,350.00 = \$14,824.01$$

La resolución prescriptiva de la Investigación de Operaciones determina formalmente que la decisión óptima para el negocio pecuario consiste en programar la distribución comercial al nivel máximo permitido por su capacidad logística, fijando la meta operativa en ciento cuarenta y nueve unidades por ciclo para capturar una utilidad neta optimizada de catorce mil ochocientos veinticuatro pesos con un centavo. Este procedimiento científico demuestra de manera contundente que la planificación fundamentada en modelos analíticos y estructuras matemáticas aporta una ventaja competitiva estructural sobre las prácticas empíricas tradicionales, permitiendo a los pequeños y medianos productores mitigar los riesgos de mercado, suprimir la dependencia de la intermediación especulativa y consolidar un modelo de agronegocio próspero, eficiente y alineado con los objetivos de justicia económica del proyecto Mercado Justo.

El sistema valida en cada vuelta del ciclo que la ganancia neta del escenario actual supera de forma consistente a la del escenario anterior. Como consecuencia de esta linealidad ascendente, el algoritmo desplaza de manera ininterrumpida el vector de decisión hacia el extremo derecho del espacio factible, descartando los puntos intermedios como soluciones subóptimas que representan un costo de oportunidad por subutilización de la capacidad instalada de transporte logístico.

Para traducir este análisis en decisiones de distribución física concretas y resolver el tendido de la red al menor costo de transporte posible, la infraestructura analítica integra soluciones empaquetadas en Python que automatizan la toma de decisiones geográficas. El sistema opera bajo un flujo de dos fases de software:

1. Optimización Estructural de la Red (Algoritmo de Kruskal): Mediante la librería matemática de grafos `networkx`, el modelo registra las coordenadas geográficas de los ocho estados clave

(nodos) y las doce conexiones posibles con sus distancias en kilómetros (aristas). El script ejecuta el algoritmo de Kruskal para evaluar de manera recursiva los pesos de los trayectos, eliminando cualquier bucle o ruta redundante. Como resultado, aísla un árbol de expansión mínima que enlaza todas las sucursales y calcula de forma exacta la distancia total optimizada de la red, asegurando la conectividad de la cadena al menor costo lineal de transporte.

2. Modelado Avanzado y Control de la Cadena de Frío: Una vez resuelto el ruteo mínimo, el sistema acopla los resultados a la librería de visualización cartográfica **folium**. El software procesa un diccionario estructurado de datos donde clasifica y etiqueta a cada entidad según su función zootécnica y comercial: los orígenes de alta producción masiva (marcadores azules), las plantas de procesamiento y empaque con certificación TIF encargadas de mantener la temperatura del producto (marcadores naranjas), y los puntos finales de consumo masivo (marcadores rojos). Finalmente, el programa traza líneas vectoriales parametrizadas (**PolyLine**) con colores diferenciados para mapear con precisión los flujos logísticos por zonas (Ruta Norte, Ruta Golfo y Ruta Occidente), consolidando un mapa interactivo apto para el control operativo.

El procedimiento iterativo alcanza su resolución definitiva al evaluar el escenario máximo permitido antes de saturar la capacidad de transporte, correspondiente a un volumen de venta de ciento cuarenta y nueve unidades ($v = 149$), que representa el límite superior estricto determinado por el rango del ciclo operativo del programa. En esta iteración culminante, el desarrollo matemático registra el cálculo final de ingresos y costos acumulados:

$$I(149) = 249.49 \times 149 = 37174.01$$

$$K(149) = 150.00 \times 149 = 22350.00$$

Al ejecutar la operación sustractiva fundamental para aislar el rendimiento neto del agronegocio, el modelo matemático concluye con la siguiente resolución exacta:

$$G(149) = 37174.01 - 22,350.00 = 14824.01$$

La resolución prescriptiva de la Investigación de Operaciones determina formalmente que la decisión óptima para el negocio pecuario consiste en programar la distribución comercial al nivel máximo permitido por su capacidad logística, fijando la meta operativa en 149 unidades por ciclo para capturar una utilidad neta optimizada de \$14,824.01 pesos.

Este procedimiento científico demuestra de manera contundente que la planificación fundamentada en modelos analíticos y estructuras matemáticas aporta una ventaja competitiva estructural sobre las prácticas empíricas tradicionales, permitiendo a los pequeños y medianos productores mitigar los riesgos

de mercado, suprimir la dependencia de la intermediación especulativa y consolidar un modelo de agronegocio próspero, eficiente y alineado con los objetivos de justicia económica del proyecto *Mercado Justo*.

A este andamiaje tecnológico e informático se integra de manera orgánica una perspectiva de género y derechos humanos orientada a deconstruir las inequidades estructurales que caracterizan al entorno rural de la región centro de México. Históricamente, las mujeres rurales han desempeñado un papel fundamental en el eslabón operativo de la ganadería bovina asumiendo tareas críticas asociadas a la gestión del corte, el cuidado zootécnico primario y la administración de los subproductos, pero su participación ha sido sistemáticamente invisibilizada y relegada al plano de la informalidad sin remuneración equitativa ni acceso formal a la propiedad agraria.

A este andamiaje tecnológico e informático se integra de manera orgánica una perspectiva de género y derechos humanos orientada a deconstruir las inequidades estructurales que caracterizan al entorno rural de la región centro de México. Históricamente, las mujeres rurales han desempeñado un papel fundamental en el eslabón operativo de la ganadería bovina asumiendo tareas críticas asociadas a la gestión del corte, el cuidado zootécnico primario y la administración de los subproductos, pero su participación ha sido sistemáticamente invisibilizada y relegada al plano de la informalidad sin remuneración equitativa ni acceso formal a la propiedad agraria. El proyecto Mercado Justo revierte este sesgo de exclusión mediante el diseño de interfaces tecnológicas con perspectiva inclusiva y la formulación de comités de gobernanza distributiva que garantizan la paridad de género en la toma de decisiones comerciales y operativas de las PyMEs pecuarias. Al empoderar económicamente a las productoras mediante canales digitales directos y eliminar las barreras financieras tradicionales, la Ciencia de Datos actúa como una herramienta de emancipación social que promueve la equidad y resguarda el derecho humano fundamental a una remuneración justa, un trabajo digno y la seguridad económica familiar en las comunidades agrarias de la región.

Para evaluar, robustecer y automatizar el diagnóstico exploratorio comercial de las 4 P's, se desarrolló e implementó una rutina de programación en Python ([Pandas](#) y [Matplotlib](#)). Esta arquitectura permite procesar de manera directa los 14,000 registros transaccionales del archivo maestro ([base_carne_14000_datos.xlsx](#)), arrojando las siguientes directrices y fundamentos técnicos por cada pilar estratégico:

- **Producto (Product):** Portfolio integral compuesto por cortes de carne fresca, carne congelada, y productos empacados al vacío. La oferta sustituye el concepto de bien genérico (*commodity*) mediante diferenciación basada en presentación, valor agregado y estrictos atributos de trazabilidad.
 - *Soporte Programático:* El código ejecuta una agrupación automatizada (`df.groupby("producto")["precio_kg"].mean()`) y genera gráficos de barras para

- diagnosticar el precio promedio por corte, aislando con precisión aquellos productos que por su rendimiento y aceptación perciben un precio premium en el mercado.
- Precio (Price): Estrategias dinámicas de precios competitivos sustentadas en la producción pecuaria a gran escala, control riguroso de costos fijos y eficiencia de rutas logísticas, lo que asegura estabilidad ante fluctuaciones exógenas.
 - *Soporte Programático*: La rutina calcula la media aritmética general del insumo (`df["precio_kg"].mean()`) y modela histogramas de frecuencia (`plt.hist`) para identificar visualmente las dispersiones y los puntos de equilibrio de las cotizaciones en la región centro.
 - Plaza (Place): Amplia cobertura de distribución con presencia diversificada en supermercados, tiendas propias, plataformas analíticas digitales y operaciones destinadas a exportaciones de alcance global.
 - *Soporte Programático*: El script segmenta financieramente el rendimiento de los canales de distribución (`df.groupby("mercado")["precio_kg"].mean()`), contrastando las métricas entre el entorno digital y el tradicional para direccionar los flujos de inventario hacia las plazas más rentables.
 - Promoción (Promotion): Comunicación estratégica orientada a nichos con alta disposición al pago, difundiendo los valores de comercio justo, equidad de género en el sector rural y las cualidades del marmoleo de la carne.
 - *Soporte Programático*: Mediante la evaluación del volumen de ventas por canal (`df.groupby("mercado")["ventas"].mean()`), el programa valida de forma estadística la efectividad de las campañas comerciales y la fuerza de la demanda en cada entorno de negocio.

Clasificación y Entornos de Mercado

- Mercado de Consumo: Integrado por familias y consumidores en México y el extranjero que adquieren carne para su alimentación diaria, marcando las tendencias de la demanda agregada.
- Mercado Industrial (B2B): Actores intermedios del sector cárnico encargados del procesamiento y engorda, e integran desde corrales de engorda intensiva, centrales de abasto, supermercados y plantas empacadoras de comercialización.
- Mercado de Servicios: Inserción del sector en los servicios tecnológicos modernos a través de sistemas analíticos de monitoreo, procesamiento de datos productivos, modelos predictivos e inteligencia artificial para optimizar decisiones.
- Mercado Institucional o de Gobierno: Entorno sujeto a regulaciones y políticas públicas de precios e insumos, el cual es monitoreado sistemáticamente mediante el análisis de fuentes de información oficiales como el [SNIIM](#), [SIAP](#), [INEGI](#), [FIRA](#) y [CONAGUA](#).
- Mercado Internacional: Operaciones de exportación pecuaria a gran escala dentro de América Latina y con fuerte destino en los Estados Unidos, actuando como un factor macroeconómico que condiciona los precios y dinámicas de comercialización locales.

Diagnóstico de Demanda Regional y Conclusiones Automáticas del Sistema

A nivel geográfico, el módulo de programación consolida las ventas totales por entidad federativa mediante agregaciones indexadas (`df.groupby("estado")["ventas"].sum().sort_values(ascending=False)`), graficando el comportamiento de la demanda para identificar las regiones con mayor tracción comercial.

Como resultado del procesamiento de este script, la rutina analítica emite de manera nativa las siguientes conclusiones estratégicas para la toma de decisiones del agronegocio:

- El corte o producto que registra el mayor precio promedio ponderado califica técnicamente para ser posicionado como una línea premium.
- El entorno de mercado digital presenta ventajas estructurales y diferencias significativas en márgenes operativos en comparación con el canal tradicional.
- El mapeo del volumen de ventas permite localizar con exactitud geográfica los mercados con mayor densidad de demanda.
- El análisis integrado de datos se consolida como la herramienta fundamental para guiar las decisiones comerciales, mitigar los riesgos de intermediación y maximizar la efectividad de las estrategias de marketing.

Todo lo que se menciona en este informe se puede observar el enlace del código que se encuentra en los anexos

PROPUESTA DE SOLUCIÓN

Nuestra propuesta de solución muestra un código que implementa una aplicación web interactiva y profesional llamada Dashboard Mercado Justo utilizando Gradio. Está diseñada específicamente para que los productores de ganado bovino en México puedan analizar datos históricos de precios, predecir tendencias mediante Inteligencia Artificial, evaluar la rentabilidad financiera de su negocio y optimizar sus rutas de distribución logística.

A continuación, se detalla de forma estructurada el funcionamiento de cada uno de sus componentes:

1. Arquitectura y Tecnologías Utilizadas

El script combina de forma robusta tecnologías de Big Data, Machine Learning y visualización interactiva:

- PySpark: Se utiliza como el motor principal para la ingesta y preparación eficiente de grandes volúmenes de datos ([base_carne_14000_datos.xlsx](#) - [Base_14000_Datos.csv](#)).
- Scikit-Learn: Aporta el soporte analítico a través de un modelo predictivo basado en el algoritmo de *Random Forest*.
- Plotly y Folium: Encargados del apartado visual, generando gráficos de dispersión/tendencias y mapas interactivos con geolocalización.
- NetworkX: Utilizado para modelar redes y aplicar algoritmos de optimización matemática (Teoría de Grafos).
- Gradio (Blocks): Actúa como la interfaz de usuario (UI), estructurando la aplicación en pestañas reactivas que actualizan los componentes visuales en tiempo real sin necesidad de recargar la página.

2. Flujo de Preparación de Datos e Ingeniería de Características

El proceso de datos se ejecuta en el backend de manera inmediata al iniciar la aplicación:

1. Lectura: PySpark carga el archivo CSV infiriendo automáticamente los tipos de datos y manejando la codificación regional ([iso-8859-1](#)).
2. Limpieza: Se eliminan los registros que contienen valores nulos o vacíos ([dropna\(\)](#)).
3. Extracción Temporal: La columna de fecha se convierte al formato adecuado para extraer variables clave: el año, el mes, el día del mes y el día de la semana. Esto permite al modelo predictivo capturar patrones de estacionalidad (por ejemplo, si el precio sube en ciertos meses o fines de semana).
4. Migración a Memoria: El DataFrame de Spark se transforma a un DataFrame de Pandas para facilitar la manipulación ágil en las librerías de visualización y modelado gráfico.

3. El Motor de Inteligencia Artificial (Random Forest)

Antes de levantar la interfaz, el sistema entrena un modelo de regresión:

- Limpieza de Strings: Corrección de formatos numéricos en variables exógenas (como cambiar las comas por puntos en las columnas de **inflacion** y **temperatura**).
- Codificación Categórica: Las variables de texto (**estado**, **producto**, **mercado** y **tipo_alimentacion**) se transforman a valores numéricos mediante **LabelEncoder**.
- Entrenamiento: Un regresor Random Forest (Bosque Aleatorio) con 100 árboles de decisión aprende la relación matemática entre el precio por kilogramo (**y**) y el conjunto de características macroeconómicas, climáticas y temporales (**X**).

4. Desglose de las Fases del Dashboard (Pestañas de la UI)

La interfaz se divide de forma muy elegante en 4 fases operativas:

Fase 1: Mercado Histórico

- Qué hace: Permite filtrar los datos por tipo de corte de carne (sirloin, arrachera, bistec, costilla) y por estado de la República Mexicana.
- Resultado Visual: Retorna un contenedor HTML (KPI) con un diseño dinámico. Si el último precio registrado está por encima del promedio histórico, se tiñe de color verde (indicando un escenario favorable para la venta); de lo contrario, se muestra en color rojo. Además, dibuja una gráfica de Plotly con el histórico diario y una línea de media móvil de 7 días para suavizar e identificar la tendencia actual del mercado.

Fase 2: IA y Predicción

- Qué hace: Es un simulador predictivo avanzado. El usuario puede mover deslizadores (*Sliders*) para definir un entorno hipotético: porcentaje de inflación, temperatura ambiental, canal de venta (ej. central de abastos o supermercados) y el tipo de alimentación del ganado.
- Resultado Visual: Al cambiar cualquier parámetro, las funciones reactivas llaman al modelo de *Random Forest* entrenado y muestran instantáneamente un bloque azul con la proyección exacta del precio estimado en pesos mexicanos (\$MXN/kg) para la fecha seleccionada.

Fase 3: Finanzas

- Qué hace: Una herramienta de control de gestión financiera enfocada en la viabilidad del negocio. El productor introduce sus costos fijos mensuales, sus costos variables por kilogramo y su meta de ganancia deseada.
- Resultado Visual: Si el costo variable supera al precio del mercado, el sistema arroja una alerta roja de inviabilidad. Si es viable, calcula matemáticamente el Punto de Equilibrio y la Meta de

Venta en Kilogramos. Adicionalmente, genera un gráfico financiero que sombrea de manera translúcida el "Área de Pérdida" (rojo) y el "Área de Ganancia" (verde), cruzando las líneas de ingresos brutos y costos totales.

Fase 4: Optimización Logística

- Qué hace: Resuelve un problema de optimización de redes utilizando la Teoría de Grafos. A partir de las conexiones logísticas y distancias entre los hubs de los estados, utiliza el Algoritmo de Kruskal para calcular el Árbol de Expansión Mínima (MST), es decir, la infraestructura de rutas óptima que conecta todos los puntos al menor costo de combustible posible.
- Resultado Visual: Muestra un mapa interactivo de Folium centrado en México. Los estados se marcan con íconos de camiones. El estado que ofrece el mejor margen neto comercial (Precio de mercado menos costos de producción y transporte) se resalta de color púrpura, mientras que los tramos óptimos de la carretera se dibujan con líneas verdes gruesas en el mapa. También despliega un KPI morado con el costo total optimizado de toda la red de distribución.

5. Reactividad y Lanzamiento ([interfaz.launch\(\)](#))

El diseño visual utiliza el tema nativo **Soft** de Gradio combinado con bloques CSS personalizados integrados mediante contenedores HTML con degradados en tonos azules corporativos.

Gracias a los oyentes de eventos ([.change\(\)](#) y [.load\(\)](#)), el dashboard es completamente reactivo: en el momento en que el usuario interactúa con un menú desplegable o arrastra un slider, los algoritmos matemáticos y los gráficos se recalculan en milisegundos, entregando una experiencia analítica fluida, intuitiva y de alto valor estratégico para el negocio cárnico.

Todo lo que se menciona en este informe se puede observar el enlace que se encuentra en los anexos

CONCLUSIÓN

El desarrollo del proyecto "Mercado Justo: Análisis y predicción de precios de productos agropecuarios" demuestra de manera contundente cómo la Ciencia de Datos para Negocios, el Big Data y la Investigación de Operaciones pueden converger para transformar un sector tradicionalmente vulnerable como la ganadería bovina en la región centro de México. A lo largo de esta investigación, se logró estructurar un ecosistema analítico robusto que mitiga eficazmente la asimetría de información y dota a los pequeños y medianos productores (PyMEs) de herramientas predictivas y prescriptivas avanzadas.

A partir del análisis e integración de los componentes clave del proyecto, se desprenden las siguientes conclusiones fundamentales:

- Eficacia del Modelado Predictivo: La implementación del algoritmo *Random Forest* (con un MAE = 14.25 y un RMSE = 17.71) demostró una alta precisión para estimar el precio por kilogramo de carne bovina en función de variables climáticas, macroeconómicas y comerciales. Al complementar este enfoque con modelos de series temporales como *ARIMA* y *Facebook Prophet*, se logró aislar la inercia temporal, las tendencias inflacionarias y los ciclos de estacionalidad, ofreciendo un horizonte de planificación financiera sumamente confiable para la gestión de la liquidez de los productores.
- Optimización Prescriptiva y Logística: El modelo de optimización lineal resolvió de forma exacta que programar la distribución al nivel máximo permitido por la capacidad logística (149 unidades por ciclo) maximiza el beneficio neto, alcanzando una utilidad optimizada de \$14,824.01 pesos. Asimismo, la integración de la Teoría de Grafos a través del algoritmo de *Kruskal* y el diseño cartográfico interactivo con *Folium* probaron que es posible interconectar la red de distribución al menor costo de transporte lineal, salvaguardando la cadena de frío y eficientando los recursos operativos.
- Diferenciación Comercial (4 P's): El procesamiento programático del portafolio comercial determinó que la transición de un esquema empírico de venta de *commodities* hacia una estrategia de precisión basada en la diferenciación del producto (cortes premium, trazabilidad y empaque al vacío) y precios dinámicos, permite a las PyMEs pecuarias direccionar sus inventarios hacia las plazas más rentables y capturar un mayor valor agregado en la cadena de suministro.

En definitiva, la solución materializada a través del *Dashboard interactivo en Gradio* no sólo valida la viabilidad metodológica de este estudio, sino que democratiza el acceso a la tecnología. "Mercado Justo" se posiciona como un modelo de agronegocio próspero, replicable, inclusivo y sustentable, sentando un precedente de cómo la ciencia de datos puede ponerse al servicio de la justicia económica y el desarrollo rural de México.

ANEXOS

- Propuesta de solución:

Enlace de la interfaz en servidor

https://huggingface.co/spaces/galileagomez08/Dashboard_Ganaderia_bovina_Mercado_Justo

Enlace de código:

<https://colab.research.google.com/drive/1GLZhsKg2DZIZxsLX1pscm50xwK4NJHnW?usp=sharing>

- Notebook de trabajo:

- Base de datos utilizada:

https://docs.google.com/spreadsheets/d/1H6V41xUt6NsVEtLNdeqAQn_XGkXQAHSaEAGJRaj_VMU/edit?usp=sharing

REFERENCIAS

- CONAGUA. (2024). *Impacto climático y disponibilidad hídrica en actividades agropecuarias*. [CONAGUA](#)
- FIRA. (2023). *Panorama agroalimentario: carne bovina*. [FIRA](#)
- Géron, Aurélien. (2022). *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow* (3.^a ed.). O'Reilly Media.
- Box, George E. P., Jenkins, Gwilym M., Reinsel, G. C., & Ljung, G. M. (2015). *Time series analysis: Forecasting and control* (5.^a ed.). Wiley.
- Hillier, Frederick S., & Lieberman, Gerald J.. (2020). *Introduction to operations research* (11.^a ed.). McGraw-Hill Education.
- INEGI. (2024). *Producto interno bruto del sector agropecuario en México*. [INEGI](#)
- James, Gareth., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An introduction to statistical learning: With applications in R* (2.^a ed.). Springer.
- NetworkX. (2024). *NetworkX documentation*. [NetworkX Official Site](#)
- Pandas. (2024). *Pandas documentation*. [Pandas Official Documentation](#)
- Prophet. (2024). *Prophet documentation*. [Prophet Documentation](#)
- PySpark. (2024). *PySpark documentation*. [Apache Spark Official Site](#)
- Russell, Stuart., & Norvig, Peter. (2021). *Artificial intelligence: A modern approach* (4.^a ed.). Pearson.
- Scikit-learn. (2024). *Scikit-learn documentation*. [Scikit-learn Official Site](#)
- SIAP. (2024). *Producción pecuaria y estadísticas de carne bovina en México*. SIAP
- SNIIM. (2024). *Precios de productos agropecuarios y cárnicos*. [SNIIM](#)
- Statsmodels. (2024). *Statsmodels documentation*. [Statsmodels Official Documentation](#)
- Taylor, James W.. (2018). *Business analytics: Data analysis and decision making* (6.^a ed.). Cengage Learning.
- Taylor, Sean J., & Letham, B. (2018). Forecasting at scale. *The American Statistician*, 72(1), 37–45. <https://doi.org/10.1080/00031305.2017.1380080>